



$x_1 = 0 \Rightarrow x_2 \uparrow \Rightarrow x_2$ 增大
 $x_1 = 1 \Rightarrow x_2 \downarrow \Rightarrow x_2$ 减小

核方法 变换空间
 后线性可分

图 6.1: 通过学习一个表示来解决 XOR 问题。图上的粗体数字标明了学得函数必须在每个点输出的值。(左) 直接应用于原始输入的线性模型不能实现 XOR 函数。当 $x_1 = 0$ 时, 模型的输出必须随着 x_2 的增大而增大。当 $x_1 = 1$ 时, 模型的输出必须随着 x_2 的增大而减小。线性模型必须对 x_2 使用固定的系数 w_2 。因此, 线性模型不能使用 x_1 的值来改变 x_2 的系数, 从而不能解决这个问题。(右) 在由神经网络提取的特征表示的变换空间中, 线性模型现在可以解决这个问题了。在我们的示例解决方案中, 输出必须为 1 的两个点折叠到了特征空间中的单个点。换句话说, 非线性特征将 $\mathbf{x} = [1, 0]^T$ 和 $\mathbf{x} = [0, 1]^T$ 都映射到了特征空间中的单个点 $\mathbf{h} = [1, 0]^T$ 。线性模型现在可以将函数描述为 h_1 增大和 h_2 减小。在该示例中, 学习特征空间的动机仅仅是使得模型的能力更大, 使得它可以拟合训练集。在更现实的应用中, 学习的表示也可以帮助模型泛化。



