

在第4.3节，我们介绍了二阶梯度方法①与一阶方法相比，二阶方法使用二阶导数改进了优化。最广泛使用的二阶方法是牛顿法。我们现在更详细地描述牛顿法，重点在其应用于神经网络的训练。

牛顿法²是基于二阶泰勒级数展开在某点 θ_0 附近来近似 $J(\theta)$ 的优化方法，其忽略了高阶导数：

① 泰勒展开：
$$J(\theta) \approx J(\theta_0) + (\theta - \theta_0)^\top \nabla_{\theta} J(\theta_0) + \frac{1}{2}(\theta - \theta_0)^\top \mathbf{H}(\theta - \theta_0), \quad (8.26)$$

其中 \mathbf{H} 是 J 相对于 θ 的Hessian矩阵在 θ_0 处的估计。如果我们再求解这个函数的临界点，我们将得到牛顿参数更新规则：

② 更新参数：
$$\theta^* = \theta_0 - \mathbf{H}^{-1} \nabla_{\theta} J(\theta_0). \quad (8.27)$$

算法 8.8 目标为 $J(\theta) = \frac{1}{m} \sum_{i=1}^m L(f(x^{(i)}; \theta), y^{(i)})$ 的牛顿法

Require: 初始参数 θ_0

Require: 包含 m 个样本的训练集

while 没有达到停止准则 **do**

 计算梯度: $\mathbf{g} \leftarrow \frac{1}{m} \nabla_{\theta} \sum_i L(f(x^{(i)}; \theta), y^{(i)})$

 计算Hessian: $\mathbf{H} \leftarrow \frac{1}{m} \nabla_{\theta}^2 \sum_i L(f(x^{(i)}; \theta), y^{(i)})$

 计算Hessian逆: \mathbf{H}^{-1}

 计算更新: $\Delta \theta = -\mathbf{H}^{-1} \mathbf{g}$ 求逆过程 优化: 二阶导数与一阶导数结合

 应用更新: $\theta = \theta + \Delta \theta$

end while



